

1. Wprowadzenie:

Dokument opisuje specyfikację wymagań oprogramowania (SRS) dla skryptu R, który przeprowadza analizę danych tekstowych z nekrologów opublikowanych w latach 2008-2026. System wczytuje plik CSV z danymi, oczyszcza je i przygotowuje korpus tekstowy, a następnie przeprowadza analizę przy wykorzystaniu trzech metod:

1. Analiza częstości słów (Word Frequency Analysis)
2. Analiza TF-IDF (Term Frequency–Inverse Document Frequency)
3. Modelowanie tematyczne LDA (Latent Dirichlet Allocation)

2. Cele systemu:

- Pobieranie danych i zapis do pliku CSV
- Oczyszczenie i przygotowanie korpusu tekstowego
- Analiza częstości słów: zliczanie popularności słów i identyfikacja trendów w treści na przestrzeni lat 2008–2026.
- Obliczanie wag TF-IDF: znajdowanie unikalnych słów kluczowych i anomalii dla konkretnych podokresów
- Modelowanie tematyczne (LDA): automatyczny podział na klastry znaczeniowe w celu wykrycia ukrytych tematów w nekrologach
- Wizualizacja wyników za pomocą wykresów trendów (ggplot2), chmur słów (wordcloud) oraz podsumowań tabelarycznych

3. Wymagania funkcjonalne:

Wczytywanie i filtrowanie danych

- Skrypt powinien wczytywać dane tekstowe z pliku csv.
- Skrypt powinien usuwać rekordy z pustą treścią nekrologu, brakiem daty oraz identyczne duplikaty wpisów.

Przetwarzanie tekstu

- Skrypt powinien zapewniać kodowanie znaków UTF-8 (poprawna obsługa polskich dodatkowych znaków).
- Skrypt powinien usuwać z tekstu adresy URL, liczby, znaki interpunkcyjne oraz stop words.
- Skrypt powinien normalizować tekst poprzez zamianę liter na małe oraz ujednolicenie wybranych form słów.

Analiza tekstu:

- Skrypt powinien tworzyć korpus tekstowy oraz macierze częstości (TDM/DTM).
- Skrypt powinien realizować techniki: analizę częstości słów, obliczanie wag TF-IDF w podziale na lata oraz modelowanie tematyczne (LDA).
- Skrypt powinien grupować dokumenty i przypisywać je do tematów na podstawie prawdopodobieństwa w modelu LDA.

Wizualizacja i raportowanie:

- Skrypt powinien generować wykresy najpopularniejszych słów oraz wykresy trendów czasowych dla wybranych słów kluczowych (ggplot2).
- Skrypt powinien generować chmury słów (wordcloud) dla całego korpusu oraz dla wyodrębnionych tematów LDA.
- Skrypt powinien tworzyć zestawienia tabelaryczne przedstawiające słowa kluczowe o najwyższych wagach TF-IDF dla poszczególnych lat.

4. Wymagania niefunkcjonalne

Wydajność:

- Analiza przykładowego zbioru CSV powinna być możliwa do uruchomienia na standardowym komputerze z zainstalowanym środowiskiem R i wymaganymi bibliotekami.
- Skrypt powinien poprawnie przetworzyć dane z nekrologów i je pogrupować.

Bezpieczeństwo:

- System powinien zapewnić poprawność danych wyjściowych.

Niezawodność:

- Skrypt powinien automatycznie odrzucać uszkodzone rekordy przed uruchomieniem analizy.
- Skrypt powinien gwarantować powtarzalność wyników LDA poprzez sztywne ustawienie ziarna losowego.

Użyteczność:

- Wykresy i chmury słów powinny być czytelne i zawierać odpowiednie etykiety.

Kompatybilność:

- Skrypt powinien być kompatybilny z R w wersji 4.0 lub nowszej.
- Skrypt powinien korzystać z bibliotek tidytext, wordcloud, tidyverse, tm, ggplot2, ggthemes, topicmodels, reshape2.

5. Interfejs użytkownika

Wejście:

- Plik CSV.

Wyjście:

- Raport HTML wygenerowany ze skryptu R
- Tabela z częstością występowania słów
- Chmury słów (wordcloud)
- Wykresy ilustrujące wyniki algorytmu LDA

6. Wymagania dotyczące danych

- Skrypt zakłada że dane są w języku polskim
- Dane wejściowe powinny być zapisane w formacie CSV i kodowaniu UTF-8
- Skrypt nie obsługuje danych w żadnym innym języku

7. Słownictwo dokumentacji:

- Korpus: zbiór dokumentów tekstowych przygotowanych do analizy
- TDM: macierz termin-dokument, w której wiersze oznaczają słowa, a kolumny dokumenty.
- Chmura słów: wizualizacja, w której wielkość słowa zależy od częstości występowania
- TF-IDF: Statystyczna miara określająca, jak ważne i unikalne jest dane słowo dla konkretnej opinii w porównaniu do całego zbioru opinii.
- Modelowanie tematyczne (Topic Modeling): Algorytmiczna technika uczenia nienadzorowanego (np. algorytm LDA), służąca do odkrywania ukrytych struktur semantycznych, abstrakcyjnych wątków i tematów dominujących w zbiorze nekrologów.

Przypadki użycia (use cases)

Użytkownik:

- wczytuje plik CSV.
- uruchamia analizę
- wyświetla wyniki

Skrypt/system:

- wczytuje dane
- przetwarza tekst
- tworzy korpus tekstowy oraz macierze częstości
- przeprowadza analizę częstości słów i generuje chmury słów
- oblicza wagi TF-IDF
- wykonuje topic modelling LDA
- produkuje raport HTML ze wszystkimi wizualizacjami i tabelami

Scenariusze użytkownika

Scenariusz 1: Analiza nekrologów w różnych kulturach

- **Jako:** Kulturoznawca
- **Chcę:** Przeanalizować treści nekrologów w badanej kulturze
- **Aby:** Zrozumieć poznać wzorce w tworzeniu nekrologów.

Kryteria akceptacji:

- Użytkownik może wczytać dane tekstowe z pliku .csv
- Użytkownik może zobaczyć w chmurze słów najczęściej występujące słowa.
- Użytkownik może dostosowywać liczbę tematów dla której będzie wykonywany algorytm LDA.
- Użytkownik może generować raporty HTML.

Scenariusz 2: Oczyszczanie i eksploracyjna analiza danych

- **Jako:** Analityk danych
- **Chcę:** Oczyszczyć i unormować dane, oraz wygenerować chmurę najczęściej występujących słów.
- **Aby:** Przeprowadzić wstępną analizę tekstów.

Kryteria akceptacji:

- Użytkownik może wczytać dane tekstowe z pliku .csv
- Po zastosowaniu funkcji czyszczących, tekst w całym korpusie jest zapisany wyłącznie małymi literami i bez interpunkcji.
- Użytkownik może zobaczyć w chmurze słów najczęściej występujące słowa.
- System generuje chmurę słów, wizualizując terminy według wagi TF-IDF.

Podział

Malina Kołodziej	część kodu, część dokumentacji, raport HTML
Zuzanna Szwej	oczyszczanie danych w R, część dokumentacji
Władysław Gutkowski	Pozyskanie danych do analizy (Web Scraping)