

1. Wprowadzenie

Naszym celem było pobranie po 50 unikalnych nekrologów, które miały co najmniej 500 znaków dla każdego roku z okresu 2008–2026 z portalu Wyborcza.pl. Baza danych portalu składa się z 3219 stron (po 100 ogłoszeń na stronie), posortowanych chronologicznie od najnowszych do najstarszych (na pierwszych stronach ogłoszenia z 2026 roku, na ostatnich z 2008 roku).

Ze względu na brak wewnętrznego filtrowania po dacie publikacji, naszym pierwszym pomysłem było przeszukanie całego zbioru. Jednak, załadowanie jednej strony trwało około 60 sekund, co przy 3219 stronach oznaczało co najmniej 54 godziny scrapowania.

2. Metoda

Przyjęliśmy więc robocze założenie, że liczba stron przypadających na każdy rok jest taka sama. Okres 2008–2026 obejmuje 19 lat, dlatego przybliżona liczba stron przypadających na jeden rok wyniosła:

$$3219/19 \approx 169$$

Przy tym założeniu, skrypt (*nekrolog_scraper_v1.R*) zaczynając od pierwszej strony przeszukuje kolejne, do momentu w którym znajdzie 50 nekrologów z 2026 roku. Po czym, przechodzi do strony, od której w teorii zaczynają się nekrologi z 2025 roku, czyli strony o numerze 169. Jednak, oczywiście założenie było mocno rygorystyczne i skrypt na stronie 169 znalazł już nekrologi z 2024 → ominął rok 2025, i zebrał dane dla 50 nekrologów z 2024 roku, po czym przeszedł do teoretycznego numeru strony dla roku 2023, czyli odpowiedniej wielokrotności liczby 169:

$$169 \cdot 3 = 507$$

I tak dalej.

Tym sposobem zebraliśmy następującą liczbę nekrologów dla poszczególnych lat:

2026:	50	2022:	0	2018:	50	2014:	0	2010:	50
2025:	0	2021:	50	2017:	0	2013:	50	2009:	50
2024:	50	2020:	0	2016:	0	2012:	50	2008:	50
2023:	0	2019:	0	2015:	50	2011:	50		

Na podstawie tego wyniku oszacowaliśmy numery stron które oddzielają konkretne lata i stworzyliśmy wektor stron od których skrypt zaczyna szukanie dla danego roku:

```
jump_map <- c(
  "2025" = 84,    "2024" = 169,    "2023" = 253,    "2022" = 338,
  "2021" = 507,   "2020" = 676,    "2019" = 845,    "2018" = 1014,
  "2017" = 1183,  "2016" = 1352,   "2015" = 1521,   "2014" = 1690,
  "2013" = 2028,  "2012" = 2366,   "2011" = 2535,   "2010" = 2791,
  "2009" = 3100,  "2008" = 3200
)
```

Szacunki okazały się być wystarczająco trafne na realizację celu. Skrypt (*nekrolog_scraper_v2.R*) w 3,5h przeszedł w sumie przez około 75 stron (zamiast 3 tys.) i zebrał po 50 nekrologów z każdego roku. Oczywiście *jump_map* to tylko praktyczna optymalizacja, a nie idealne rozwiązanie. Gdybyśmy zwiększyli docelową liczbę pobranych ogłoszeń z każdego roku, mogłoby się okazać, że dla części lat konieczne byłoby cofnięcie się o kilka stron wcześniej. Mapa stron startowych nie wyznacza więc dokładnych granic między latami, lecz jedynie przybliżone miejsca w bazie, od których najbardziej opłacało się rozpocząć wyszukiwanie. W naszym przypadku było to jednak wystarczające.

3. Architektura skryptu *nekrolog_scraper_v2.R*

Skrypt realizuje cel: pobranie określonej liczby (*max_obits*) unikalnych nekrologów o określonej minimalnej długości znaków (*min_chars*) dla każdego roku z okresu 2008–2026 opublikowanych na nekrologi.wyborcza.pl. Jego działanie opiera się na zoptymalizowanej pętli i czterech filarach technicznych:

- **Ekstrakcja i czyszczenie HTML:** Skrypt pobiera kod HTML strony zawierającej listę wyników, a następnie mapuje węzły poszczególnych ogłoszeń za pomocą pakietu *rvest*. Wyciąga z nich datę publikacji oraz docelowy link. Następnie program wywołuje funkcję pomocniczą, która parsuje stronę konkretnego nekrologu. Funkcja ta ekstrahuje informacje o regionie i autorze, a także odnajduje główny węzeł tekstowy (*#ogl*).
- **Weryfikacja i deduplikacja:** Każdy pobrany tekst musi spełnić warunek minimalnej długości *min_chars* znaków. Następnie jest on konfrontowany z dynamicznym wektorem *seen_texts*. Jeśli skrypt natrafi na ogłoszenie o identycznej treści (nawet pod innym adresem URL), odrzuca je.
- **Nawigacja skokowa:**
 - **W POPRZEDNIEJ wersji - *nekrolog_scraper_v1.R*:** Gdy zbierze *max_obits* nekrologów dla badanego roku, przerywa czytanie aktualnej strony, wykonuje skok do strony, której numerem jest odpowiednia wielokrotność liczby 169:

```
page_num <- 169 * (2026 - as.numeric(year) + 1)
```
 - **W tej wersji - *nekrolog_scraper_v2.R*:** Gdy zbierze *max_obits* nekrologów dla badanego roku, przerywa czytanie aktualnej strony, odczytuje docelową wartość z wektora *jump_map* i wykonuje skok do predefiniowanej strony następnego roku:

```
page_num <- jump_map[[target_year]]
```
- **Odporność na błędy (Error Handling):** Zapytania HTTP zabezpieczono blokiem *tryCatch* i pętlą ponowień. Przy braku odpowiedzi serwera, algorytm ponawia próbę do 10 razy. Ponadto w przypadku ręcznego przerwania skryptu przez użytkownika, program zapisuje zebrane do tego momentu dane do pliku CSV, zapobiegając utracie postępu.